


Deep Learning: Advanced Models and Methods (DL26)

Track 18: State-Space Models (Mamba) for Mistake Detection

LeMeCla


Damiano Messina, Claudio Nuncibello, Emanuele Barbagallo



La sfida delle sequenze video a lungo termine




TRANSFORMER



Complessità Computazionale e
Memoria Quadratica $O(N^2)$



LSTM CLASSICHE



Memory Decay
(Decadimento della Memoria)
su dipendenze a lunghissimo
termine

Dataset e Task


Task: Classificazione densa (frame-by-frame) a 3 classi.

1.  Correct (~77%): Esecuzione standard.
2.  Mistake (~16%): Istante esatto dell'errore.
3.  Correction (~7%): Azione di ripristino.


Le Sfide: Sbilanciamento estremo e sequenze immense (fino a 20.000+ frame).

Assembly101

<https://assembly-101.github.io/>




Focal Loss




Focal Loss + Class Weights: compensano la rarità delle classi e azzerano il rumore dei campioni troppo facili.
Tutta l'attenzione dell'addestramento va solo ai rari frame in cui il modello si confonde.

Gelu (Gaussian Error Linear Unit)

- Risolve il "Dying ReLU": Permette il passaggio di piccoli gradienti negativi, salvando i neuroni inattivi.
- Curve morbide: Flusso del gradiente migliore e stabilità su dipendenze sequenziali non-lineari.
- Regularizzazione Naturale: Agisce come un "dropout stocastico" direttamente nella funzione di attivazione.



Baseline




Recent Past: Estrae finestre locali strettissime per catturare variazioni ad altissima frequenza.


Spanning Past (RoI Pooling 1D): Comprime l'intera storia passata con dimensione costante e preserva la struttura anziché collassarla in un unico vettore.

Il Vantaggio Architettonico

Mamba






xLSTM





Mamba e xLSTM ingeriscono interi video non tagliati
(fino a 20.000+ frame) in un solo passaggio.



TempAGG (baseline)




mamba




xLSTM



Analisi qualitativa



TempAGG (baseline)



mamba



xLSTM



Esperimenti e Risultati

Modello	Parametri Trainabili	Lunghezza Sequenza	Miglior Val Loss	Test Loss	Test Correct F1	Test Mistake F1	Test Correction F1	Test Macro F1
BASELINE 1	9.06M	8000	0.4863	0.7087	93.35%	25.13%	2.91%	40.46%
BASELINE 2	2.53M	8000	0.3611	0.6847	94.16%	25.62%	1.61%	40.46%
MAMBA 1	11.36M	None	0.5371	1.7684	95.62%	13.99%	4.38%	37.99%
MAMBA 3	11.36M	12000	0.2959	0.4673	93.75%	15.18%	1.84%	36.92%
MAMBA 4	11.36M	8000	0.2261	0.2605	93.76%	10.88%	1.61%	35.41%
MAMBA 6	3.19M	12000	0.3002	0.5340	95.05%	10.45%	2.12%	35.87%
XLSTM 1	10.89M	8000	0.3303	0.9828	95.84%	10.85%	1.25%	35.98%
XLSTM 2	4.54M	8000	0.6906	0.9915	94.28%	13.69%	3.07%	37.01%

Limiti del progetto

01

Hardware

02

Dataset

03

Architetture

04

Task

Conclusioni

Traguardo Raggiunto: Il paradigma *Whole-Video* con Mamba e xLSTM abbatte il muro della memoria quadratica, processando video da 20.000+ frame senza tagli.

Il Trade-off: Su task "ad altissima frequenza" (micro-errori di pochi frame), i modelli a stato globale sfocano il dettaglio chirurgico, dove invece eccelle la convoluzione locale.

Sviluppi Futuri:

Reti Ibride: Fondere un estrattore locale (Conv) con un tracciatore storico globale (Mamba).

Multimodalità: Integrare il tracking 3D delle mani per superare l'inevitabile ambiguità visiva.